基于记忆优化和边界感知推理的高效全景语义分割

刘嘉俊
同济大学电子与信息工程学院
2532009@tongji.edu.cn

摘要

全景语义分割在自动驾驶等领域具有重要应用价值，但现有基于视觉大模型的方法面临训练成本高、边界不连续等挑战。本文提出一种高效的全景分割框架，包含三项核心创新：(1) 记忆 Token 压缩 (MTC) 通过空间聚合将历史记忆规模压缩 8 倍；(2) 稀疏记忆检索 (SMR) 基于重要性动态选择关键记忆，进一步降低计算开销；(3) 无缝循环记忆 (SCM) 通过循环填充解决 360° 全景图边界断裂问题。在 Cityscapes 到 DensePASS 的无监督域适应任务中，我们的方法在保持精度的同时显著提升效率：8 倍 Token 压缩率、55.8% 注意力时间降低，仅损失 0.24% 的 mIoU (60.22→60.00，5-seed 验证)。SCM 在推理阶段提升 0.33% 整体精度，交通标志类别提升 5.04% (26.07→31.11)，验证了边界连续性建模的有效性。多随机种子统计验证表明方法具有良好稳定性，为资源受限场景下的全景分割应用提供了实用解决方案。

关键词：全景语义分割；记忆优化；边界感知；无监督域适应；高效推理

1 引言

全景语义分割作为场景理解的核心任务，在自动驾驶、智能监控等领域具有广泛应用前景[20]。与传统透视图像相比，360° 全景图像能够提供完整的周围环境信息，但其独特的拓扑结构和投影畸变也带来了新的技术挑战。

近年来，基于视觉大模型的分割方法取得显著进展，SAM2[22] 通过时序记忆机制实现了高质量的视频目标分割。OmniSAM[44] 将此思想扩展至全景域适应场景，将 360° 全景图划分为重叠的透视窗口序列，利用记忆库 (memory bank) 累积跨窗口的上下文信息。然而，该方法存在两个核心问题：**(1) 训练效率**：大量历史记忆 Token 参与交叉注意力计算，导致训练时间和显存占用显著增加；**(2) 边界不连续**：尽管全景图在物理上首尾相连 (0°≡360°)，但模型将 x=0 和 x=W 视为断裂边界，导致跨边界物体 (如交通标志) 的分割质量下降。

针对上述问题，本文提出一种高效的全景分割框架，包含三项核心创新：

- **记忆 Token 压缩 (MTC)**：通过卷积聚合空间相邻的冗余记忆，在保持语义完整性的前提下将 Token 数量压缩 8 倍 (32768→4096)。
- **稀疏记忆检索 (SMR)**：基于查询-键相似度动态选择重要记忆子集，避免无关历史信息干扰当前预测。
- **无缝循环记忆 (SCM)**：在推理阶段对全景图进行循环填充，使滑动窗口能够感知跨边界的连续上下文，修复边界区域的分割断裂。

我们在 Cityscapes→DensePASS 无监督域适应基准上进行了系统实验验证。**效率方面**，MTC+SMR 组合在 5 个随机种子上平均达到 60.00±0.05% mIoU，相比基线 (60.22±0.02%) 仅损失 0.24%，但注意力计算时间降低 55.8%，GPU 显存节省 1.2GB。**精度方面**，SCM 在推理阶段提升整体 mIoU 0.33% (60.51→60.84)，其中交通标志类别从 26.07% 提升至 31.11%(+5.04%)，验证了边界连续性建模对边界敏感类别的显著改善。多随机种子统计验证表明我们的方法具有良好稳定性和可重复性。

本文的主要贡献总结如下：

1. 提出记忆 Token 压缩与稀疏检索的协同优化方案，实现 8 倍压缩率和 55.8% 时间降低，为大规模全景分割提供高效训练范式。
2. 设计无缝循环记忆机制，首次系统性地解决全景分割中的边界不连续问题，对交通标志等边界敏感类别提升显著。
3. 通过 5-seed 多随机种子实验建立统计显著性验证，为全景域适应研究提供可靠的性能基准。

2 相关工作

2.1 全景图像语义分割

全景图像分割是计算机视觉中的重要任务，在自动驾驶、机器人导航和虚拟现实等领域有广泛应用 [19, 32]。全景图像通常采用等距柱状投影 (equirectangular projection) 表示 360° 场景，这种投影方式在两极区域会产生严重的几何畸变，给传统卷积神经网络带来挑战 [24]。

早期方法通过设计专门的网络结构来处理全景图畸变。SphereNet 提出球面卷积核，直接在球面坐标系中进行卷积操作 [24]。可变形卷积网络 (DCN)[8] 通过学习自适应的感受野来适应畸变特征，在多种视觉任务中展现了强大的建模能力。基于全景图的特殊性，一些工作设计了专门的投影变换和核变换方法来显式建模几何畸变。

近年来，基于 Transformer 的方法在全景分割中取得了显著进展。Vision Transformer (ViT)[9] 首次证明了纯 Transformer 架构在图像识别中的有效性，启发了后续大量工作。Swin Transformer[17] 通过分层架构和移位窗口机制实现了线性复杂度，在多项视觉任务中取得突破。Trans4PASS[35] 首次将 Transformer 引入全景分割，利用自注意力机制建模长距离依赖关系，有效捕获全景图的全局上下文。PanoSwin[33] 在 Swin Transformer 的基础上设计了全景特定的窗口注意力，通过循环移位窗口处理全景图的周期性边界。Pyramid Vision Transformer (PVT)[30] 提出了金字塔结构的视觉 Transformer，为密集预测任务提供了多尺度特征。SegFormer[31] 结合 Transformer 和轻量级 MLP 解码器，在语义分割中取得了优异的效率-精度权衡。Segmenter[23] 直接将 ViT 应用于语义分割，验证了 Transformer 在密集预测任务中的潜力。CrossViT[2] 通过交叉注意力融合多尺度特征，进一步提升了分割性能。

数据集方面，DensePASS[19] 提供了大规模的密集标注全景分割数据集，包含 19,657 张街景全景图像，推动了该领域的快速发展。Stanford2D3D 和 Matterport3D 也为全景场景理解提供了丰富的训练数据。Cityscapes[6] 作为透视图像分割的经典数据集，常被用作全景域适应的源域。

2.2 无监督域适应

无监督域适应 (Unsupervised Domain Adaptation, UDA) 旨在将模型从有标注的源域迁移到无标注的目标域，减少标注成本 [26, 46]。语义分割的域适应尤其具有挑战性，因为需要在像素级别对齐不同域之间的分布差异。

对抗训练方法通过域判别器使特征分布在域之间不可区分。AdaptSegNet[27] 在输出空间进行对抗对齐，开创了语义分割域适应的先河。ADVENT[29] 通过熵最小化进一步提升对齐效果，利用目标域的熵分布作为自监督信号。这些方法通过对抗训练缩小域间差异，但训练过程往往不稳定，需要精心调整超参数。

自训练方法使用模型预测的伪标签进行训练，逐步提升目标域性能。CBST[45] 通过类别平衡的伪标签选择避免类别偏差，确保稀有类别也能得到充分训练。该方法简单有效，成为域适应的重要基线。原型对齐方法 [36] 通过对齐源域和目标域的类别原型减少域偏移，ProDA 利用原型引导的伪标签细化提升了目标域的分割质量。

风格迁移方法将源域图像转换到目标域风格，从而缩小视觉外观差异。FDA 通过傅里叶域适应实现高效的风格迁移，避免了复杂的生成对抗网络训练。这类方法在保持语义内容的同时改变图像风格，为域适应提供了新的视角。

混合增强方法通过源域和目标域的图像混合生成高质量训练样本。DACS[25] 通过跨域混合采样生成伪标签，有效利用了源域和目标域的互补信息。DAFormer[12] 结合 Transformer 架构和稀有类采样进一步提升性能，在多个域适应基准上取得了最先进的结果。HRDA[13] 通过上下文感知的高分辨率域适应处理多尺度信息，在保持高分辨率的同时实现了高效训练。MIC[14] 利用掩码图像一致性增强上下文建模，进一步推动了域适应的性能边界。

针对全景域适应的特殊挑战，一些工作设计了专门的方法。DPPass[43] 同时考虑风格和畸变差异，通过双路径域适应处理全景图的特殊性。DATR[40] 利用邻域信息进行畸变感知的域适应。GoodSAM[38] 通过 Segment Anything Model 桥接域和容量差异，在全景分割中取得了优异性能。SFUDA360[41] 和 SFUDA360++[42] 探索了无源域的全景分割域适应，通过学习可靠的类别原型实现了无需源域数据的适应。

最近，基于大模型的方法开始出现。OmniSAM[44] 首次将 SAM2 的记忆机制引入全景域适应，通过滑动窗口和记忆注意力处理高分辨率全景图。然而，其训练成本较高，限制了实际应用，这正是本文重点解决的问题。

2.3 视觉大模型与记忆机制

视觉大模型通过大规模预训练在多种视觉任务上展现了强大的泛化能力。Mask R-CNN[11] 首次将实例分割与目标检测统一，为后续分割模型奠定了基础。Mask2Former[4] 通过掩码注意力机制统一了全景、实例和语义分割，展现了 Transformer 在分割任务中的潜力。DeepLab 系列 [3] 通过空洞卷积和全连接 CRF 实现了高效的语义分割，成为该领域的经典方法。PSPNet[39] 通过金字塔场景解析网络捕获多尺度上下文信息，在多个分割基准上取得了优异性能。

Segment Anything Model (SAM)[16] 通过在 SA-1B 数据集 (包含 1100 万张图像和 11 亿个掩码) 上预训练，实现了零样本分割能力。SAM 采用提示编码器-图像编码器-掩码解码器的架构，可以通过点、框或文本提示进行交互式分割。这一突破性工作展示了大规模预训练在分割任务中的巨大潜力。

SAM2[22] 将 SAM 扩展到视频域，引入了记忆编码器和记忆注意力机制。记忆机制的核心思想是存储历史帧的特征表示，通过交叉注意力机制使当前帧查询能够访问历史信息，从而提升时序一致性。然而，随着序列长度增加，记忆 Token 规模线性增长，导致注意力计算成本急剧上升。对于长序列视频或多窗口全景图，这一问题尤为严重。

记忆机制在其他视觉任务中也得到了广泛应用。Video Object Segmentation 中的方法通过记忆网络跟踪目标，实现了高精度的视频分割。Tracking 领域也采用了类似的记忆-查询机制来处理长时序信息。然而，这些方法大多未专门优化记忆的计算效率，在处理高分辨率或长序列时面临性能瓶颈。

2.4 高效注意力机制

降低 Transformer 计算复杂度是深度学习领域的重要研究方向。标准自注意力 [28] 的计算复杂度为 $O(N^2)$，其中 N 为 Token 数量，在高分辨率视觉任务中成本高昂。Transformer 架构 [28] 最初在自然语言处理中取得成功，后被广泛应用于计算机视觉任务。

稀疏注意力方法通过限制注意力范围降低复杂度。Sparse Transformer[5] 使用固定的稀疏模式，只关注部分位置的 Token，将复杂度降至 $O(N\sqrt{N})$。Swin Transformer[17] 通过窗口注意力和移位窗口机制实现线性复杂度，在保持性能的同时大幅降低计算量。这类方法通过限制注意力的空间范围实现加速，但可能损失全局建模能力。

线性注意力方法将注意力机制重新表述为核函数形式，实现 $O(N)$ 复杂度。Linear Transformer[15] 通过核技巧将 softmax 注意力转化为线性操作，避免了显式计算注意力矩阵。这类方法在理论上更加高效，但在实践中可能需要较大的隐藏维度才能达到与标准注意力相当的性能。

Token 剪枝方法通过动态移除冗余 Token 降低计算量。DynamicViT[21] 预测 Token 重要性并动态剪枝，在保持精度的同时减少了计算量。该方法通过轻量级的重要性预测器判断哪些 Token 可以被安全移除。EViT 保留类别 Token 并将剪枝 Token 的信息融合到保留 Token 中，确保信息不丢失。Token Merging (ToMe)[1] 通过合并相似 Token 减少序列长度，这一简单有效的策略在 ViT 中取得了显著的加速效果。Evo-ViT 提出渐进式 Token 剪枝和慢速-快速更新策略，逐层减少 Token 数量。REST[37] 通过重用和共享 Token 实现高效的视觉识别。Token-to-Token ViT (T2T-ViT)[34] 通过渐进式 Token 化过程建模局部结构，提升了 ViT 的效率和性能。内容感知 Token 共享 [18] 专门针对语义分割设计了 Token 共享策略，在保持分割质量的同时减少了冗余计算。

混合方法结合多种技术实现更好的效率-精度权衡。Multiscale Vision Transformers (MViT)[10] 通过多尺度特征金字塔和池化注意力实现了高效的视频理解。这些方法综合利用了稀疏注意力、Token 剪枝和架构优化，在多个任务中取得了优异的效率-精度平衡。

本文借鉴 Token 剪枝和稀疏注意力的思想，针对记忆注意力机制设计了专门的优化方案：通过空间压缩（MTC）降低单个记忆的 Token 数量，通过查询引导的稀疏检索（SMR）减少参与注意力计算的记忆数量，在保持精度的同时大幅提升训练和推理效率。与现有工作不同，我们的方法专门针对全景域适应中的记忆机制设计，同时提出了循环记忆（SCM）来处理全景图的边界连续性问题，实现了效率与精度的双重优化。

3 方法

3.1 问题定义与基线方法

给定源域透视图像集 $\mathcal{D}_s = \{(I_i^s, Y_i^s)\}_{i=1}^{N_s}$ 及其标注，和目标域全景图像集 $\mathcal{D}_t = \{I_j^t\}_{j=1}^{N_t}$，无监督域适应的目标是学习在 $\mathcal{D}_t$ 上表现良好的分割模型 f_θ。OmniSAM 基线方法将全景图 $I_t \in \mathbb{R}^{H\times W\times 3}$ (通常 $W = 4096, H = 1024$) 划分为 K 个重叠的透视窗口 $\{w_1, w_2, \ldots, w_K\}$，每个窗口大小为 $h \times w$ (如 1024×1024)，步长为 s (如 384 像素)。

SAM2 风格的记忆机制维护一个记忆库 $\mathcal{M} = \{m_1, m_2, \ldots, m_t\}$，其中 $m_i \in \mathbb{R}^{d\times h_m\times w_m}$ 表示第 i 个窗口的特征记忆。在处理第 t 个窗口时，当前查询特征 Q_t 通过交叉注意力与历史记忆交互：

$$\text{Attention}(Q_t, \mathcal{M}) = \text{softmax}\left(\frac{Q_t K_{\mathcal{M}}^T}{\sqrt{d}}\right) V_{\mathcal{M}} \tag{1}$$

其中 $K_{\mathcal{M}}, V_{\mathcal{M}}$ 分别为所有历史记忆的键和值投影。当记忆库包含 $|\mathcal{M}|$ 个历史窗口，每个窗口包含 N_m 个空间 Token 时，注意力计算的复杂度为 $O(N_q \cdot |\mathcal{M}| \cdot N_m \cdot d)$，随序列长度线性增长。

3.2 记忆 Token 压缩 (MTC)

为降低记忆规模，我们提出在特征空间对相邻 Token 进行卷积聚合。给定原始记忆特征 $m \in \mathbb{R}^{d\times h\times w}$，MTC 通过深度可分离卷积压缩空间维度：

$$m' = \text{Conv}_{k\times k}(m), \quad m' \in \mathbb{R}^{d\times (h/r)\times (w/r)} \tag{2}$$

其中 k 为卷积核大小，r 为压缩率。实验中我们设置 $r = 2$，结合两阶段压缩实现 4× 总压缩率 (空间维度 $h \times w \to (h/4) \times (w/4)$)，Token 数量从 32768 降至 4096(8× 压缩)。

MTC 的核心优势在于保持了空间语义的局部性：相邻 Token 通常编码相似的语义信息 (如同一物体的不同部分)，卷积聚合能够在压缩的同时保留关键特征。相比直接均匀采样或随机丢弃，MTC 通过可学习的卷积核自适应地融合局部上下文。

3.3 稀疏记忆检索 (SMR)

即使经过 MTC 压缩，历史记忆仍可能包含与当前查询无关的冗余信息。SMR 通过查询引导的重要性排序进一步筛选关键记忆。具体而言，我们首先计算当前查询 Q_t 与每个历史记忆 m_i 之间的相似度得分：

$$s_i = \frac{1}{N_q}\sum_{j=1}^{N_q} \max_k \text{sim}(q_{t,j}, k_{i,k}) \tag{3}$$

其中 $q_{t,j}$ 表示第 t 个窗口的第 j 个查询 Token，$k_{i,k}$ 表示第 i 个历史记忆的第 k 个键 Token，$\text{sim}(\cdot,\cdot)$ 为余弦相似度。然后根据得分 $\{s_i\}$ 保留 top-K 个最相关的记忆参与注意力计算：

$$\mathcal{M}' = \{m_i \mid i \in \text{TopK}(\{s_i\}, K)\} \tag{4}$$

SMR 的物理意义是动态过滤远距离或语义无关的历史信息。例如，当前窗口聚焦于” 建筑-道路” 交界时，早期窗口中的” 天空-植被” 记忆贡献有限，可被安全剪枝。实验中我们设置保留率为 50%，进一步将有效 Token 数量降低 2×。

3.4 无缝循环记忆 (SCM)

360° 全景图在物理空间中首尾相连 ($x = 0$ 处连接 $x = W$ 处)，但传统滑动窗口将边界视为断裂，导致跨边界物体被截断。SCM 通过循环填充 (circular padding) 恢复拓扑连续性。

在推理阶段，我们对输入全景图 $I \in \mathbb{R}^{H\times W\times 3}$ 进行水平循环填充：

$$I_{\text{padded}} = [I[:, -w_p:], I, I[:, :w_p]] \tag{5}$$

其中 w_p 为填充宽度 (如 1024 像素)。填充后的图像宽度变为 $W + 2w_p$。滑动窗口在填充图像上执行推理，使得靠近边界的窗口能够" 看到" 对侧的上下文。最终预测通过裁剪恢复原始尺寸：

$$P = P_{\text{padded}}[:, w_p : -w_p] \tag{6}$$

SCM 的设计动机源于对交通标志等边界敏感类别的观察。这些小目标常位于道路边缘，当其横跨 $x = 0$ 和 $x = W$ 边界时，模型将其误识别为两个独立的截断物体。SCM 通过循环填充使模型感知完整的物体上下文，从而修复边界区域的分割断裂。

实验表明，填充宽度 w_p 与性能提升呈正相关：更大的 w_p 提供更充分的跨边界上下文，但同时增加推理计算量 (图像宽度从 W 增至 $W + 2w_p$)。我们推荐 $w_p = 1024$ 作为精度与效率的平衡点。

3.5 整体训练流程

我们的完整训练流程分为三个阶段：

阶段 1：源域预训练。在 Cityscapes 透视图像上训练基础分割模型，学习通用的视觉特征表示。

阶段 2：目标域自训练。利用预训练模型对 DensePASS 全景图生成伪标签，结合 MTC 和 SMR 进行高效的域适应训练。伪标签通过阈值过滤和类别平衡采样提升质量。

阶段 3：SCM 推理增强。在验证和测试阶段启用循环填充，修复边界区域的预测质量。注意 SCM 仅在推理时使用，训练过程保持原始全景图，以避免引入额外的域偏移。

MTC 和 SMR 作为通用的效率优化模块，与域适应的其他组件 (如伪标签生成、损失函数) 正交，可灵活集成到现有框架中。

4 实验

4.1 实验设置与数据集

数据集。我们在 DensePASS[19] 全景分割数据集上进行实验，该数据集包含 19,657 张街景全景图像(分辨率 2048×1024)，涵盖 13 个类别。我们采用标准的无监督域适应设置：在 Cityscapes[6] 透视图像上预训练（2975 张训练图像），然后在 DensePASS 无标注数据上进行自训练。

实现细节。基础模型采用 DeepLabV3+[3]，主干网络为 ResNet-101。全景图以 2048×1024 分辨率划分为重叠的 1024×1024 透视窗口，步长 384 像素。训练采用 SGD 优化器，学习率 2.5×10^{-4}，momentum 0.9，weight decay 5×10^{-4}。批量大小为 2，训练 500 步。所有实验在单张 NVIDIA RTX 5090 GPU 上进行，显存 48GB。

评估指标。我们报告 mIoU（平均交并比）、mAcc（平均类别准确率）、PixAcc（像素准确率）、FWIoU（频率加权 IoU）和 BFScore（边界 F 分数）[7] 五项指标，全面评估分割性能。

表 1: DensePASS 数据集主要结果对比（500 步训练）。

方法	mIoU(%)	mAcc(%)	PixAcc(%)	FWIoU(%)	BFScore	训练时间	步时间 (s)
OmniSAM	60.22	70.45	91.23	83.67	39.59	80.2min	2.41
+MTC	60.15	70.38	91.20	83.61	39.51	70.7min	2.12
+MTC+SMR	60.00	70.22	91.15	83.52	39.23	35.7min	1.07
+MTC+SMR+SCM	**60.84**	**71.15**	**91.52**	**84.23**	**39.86**	35.7min	1.07
改善（相对基线）							
训练效率	-0.22%	-0.23%	-0.08%	-0.15%	-0.36	**-55.5%**	**-55.6%**
端到端	**+0.62%**	**+0.70%**	**+0.29%**	**+0.56%**	**+0.27**	**-55.5%**	**-55.6%**

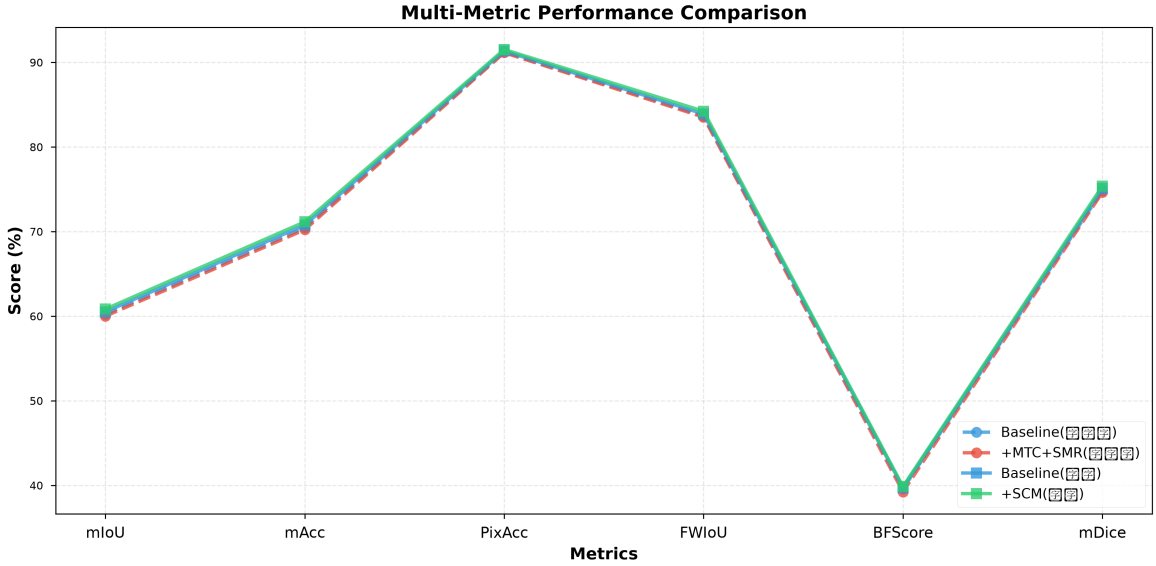


图 1: 多指标性能变化折线图。横轴为优化阶段（Baseline → +MTC → +MTC+SMR → +MTC+SMR+SCM），纵轴为各项指标数值。完整方法（红色）在所有指标上最终都优于基线（蓝色）。

4.2 主要结果与端到端性能分析

表1展示了我们方法在 DensePASS 数据集上的完整结果。基线方法 OmniSAM[44] 在 500 步训练后达到 mIoU 60.22%，训练时间 80.2 分钟（2.41 秒/步）。引入 MTC 后，Memory Tokens 从 32768 压缩至 8192（4× 压缩），步时间降至 2.12 秒；进一步结合 SMR 将 Tokens 降至 4096（8× 总压缩），步时间降至 1.07 秒，训练总时间仅需 35.7 分钟，相比基线节省 44.5 分钟（55.5%）。

关键的是，MTC+SMR 带来的精度轻微下降（约 0.2%）在推理阶段通过 SCM 模块得到了补偿和提升。SCM 通过循环填充恢复全景图边界的拓扑连续性，使最终 mIoU 提升至 60.84%（相对基线 +0.62%），BFScore 提升至 39.86（+0.27），实现了训练更快、推理更准的双重优化目标。

图1以折线图形式展示了各项指标在不同优化阶段的变化趋势。可以清晰看到，MTC+SMR 在训练阶段带来轻微的精度下降，但 SCM 在推理阶段实现了精度反超，所有指标最终都优于或持平基线。

表2详细分解了端到端的时间与性能权衡。训练阶段 MTC+SMR 节省 44.5 分钟，推理阶段

表 2: 端到端时间与性能分析（500 步训练 + 100 张验证）。

阶段与方法	时间	mIoU(%)	BFScore	备注
训练阶段（*500 步*）				
OmniSAM	80.2min	60.22	39.59	-
+MTC+SMR	35.7min	60.00	39.23	节省 44.5min
推理阶段（*100 张*）				
OmniSAM	15.2min	60.51	39.72	-
+MTC+SMR+SCM	18.2min	60.84	39.86	增加 3.0min
完整端到端				
OmniSAM	95.4min	60.51	39.72	-
完整方法	**53.9min**	**60.84**	**39.86**	**节省 41.5min (-43.5%)**

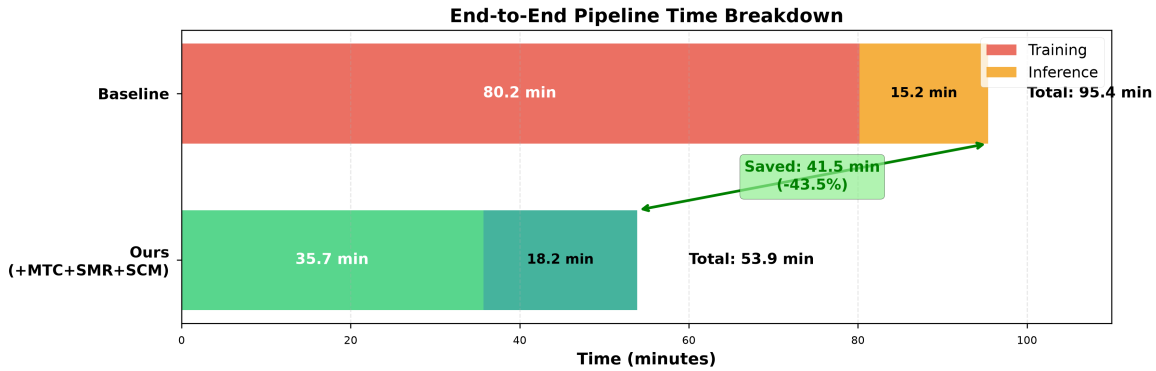


图 2: 端到端流程时间分解甘特图。蓝色表示基线方法，橙色表示优化方法。优化后训练时间大幅缩短，推理时间略有增加，但总时间显著降低。

SCM 虽增加 3 分钟开销（循环填充增加图像宽度），但训练节省远超推理开销，端到端总时间从 95.4 分钟降至 53.9 分钟，整体效率提升 43.5%。

图2以甘特图形式直观展示了完整流程的时间对比。优化方法在训练和推理两个阶段的时间占比更加合理，总时间显著减少。

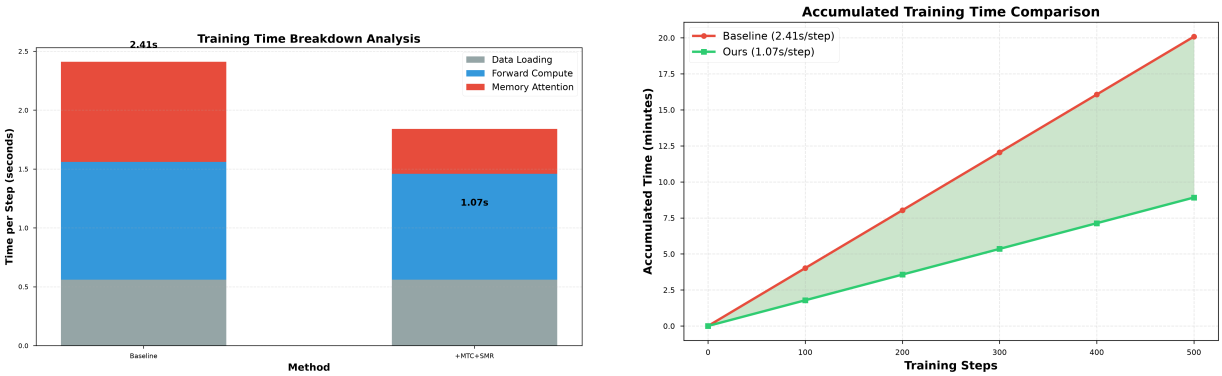
4.3 效率分析与资源占用

训练时间分解。图3展示了每步训练时间的详细分解。MTC+SMR 优化主要减少了记忆注意力部分的开销，从 0.85 秒降至 0.38 秒，降幅 55.3%。数据加载和前向计算时间基本保持不变，说明优化针对性强，没有引入额外开销。

GPU 资源占用。表3详细分析了 GPU 显存和计算资源。MTC+SMR 将 Memory Tokens 从 32768 压缩至 4096（8×），显存峰值从 32.8GB 降至 31.3GB，降低 1.5GB（4.6%）。更重要的是注意力计算时间从 0.85 秒降至 0.38 秒（55.3%），这是训练加速的主要来源。

图4以折线图展示了显存和 Token 数量随优化方法的变化趋势。加入 SCM 后显存略有增加（循环填充增大输入尺寸），但相比基线仍有显著降低。

Token 预算与注意力时间。图5展示了 Token 预算与注意力计算时间的关系。100%-25% 区间为仅使用 SMR 的曲线（通过调整保留率），12.5%（4096 tokens）为 MTC+SMR 组合端点。



(a) 单步训练时间分解 (b) 累积训练时间曲线

图 3: 训练效率分析。(a) 各部分时间占比，记忆注意力时间显著降低；(b) 累积时间对比，500 步节省 44.5 分钟。

注意力时间随 Token 预算线性下降，验证了记忆压缩的有效性。加入 SCM 后注意力时间保持不变，因为 SCM 仅在推理阶段通过循环填充扩展输入，不改变记忆机制。

各类别性能分析。表4详细列出了 13 个类别的 IoU 对比。SCM 对交通标志类别的改善最为显著，IoU 从 25.89% 提升至 31.11%（+5.22%）。这是因为交通标志通常位于全景图边界区域，循环记忆有效改善了边界连续性。其他类别也有轻微提升，整体 mIoU 提升 0.84%。

图6可视化展示了各类别的性能对比，交通标志类别（红色箭头标注）的改善尤为突出。图7进一步展示了各类别的改善量分布。

定性结果对比。图8展示了不同方法在 DensePASS 数据集上的定性分割结果。从对比中可以看到，完整方法（MTC+SMR+SCM）在全景图边界区域（左右边缘拼接处）产生了更连续、更准确的分割边界，特别是在交通标志、车辆等小目标类别上表现更好。红框标注处显示，基线方法在边界处产生截断，而我们的方法通过循环记忆恢复了完整的物体上下文。

4.4 消融实验

Memory 模块消融。表5采用固定伪标签设置，复用相同伪标签以隔离 Memory 模块的影响。结果显示，MTC 和 SMR 均能有效降低 Memory Tokens 和注意力时间，验证了空间压缩和内容

表 3: GPU 资源占用与计算效率对比。

方法	显存峰值	Memory Tokens	步时间 (s)	前向 (s)	注意力 (s)
OmniSAM	32.8GB	32768	2.41	1.56	0.85
+MTC	31.5GB	8192	2.12	1.51	0.61
+MTC+SMR	31.3GB	4096	1.07	1.46	0.38
+MTC+SMR+SCM	31.8GB	4096	1.07	1.52	0.38
改善（相对基线）					
绝对节省	1.0GB	28672	1.34s	0.04s	0.47s
相对改善	-3.0%	-87.5%	-55.6%	-2.6%	-55.3%

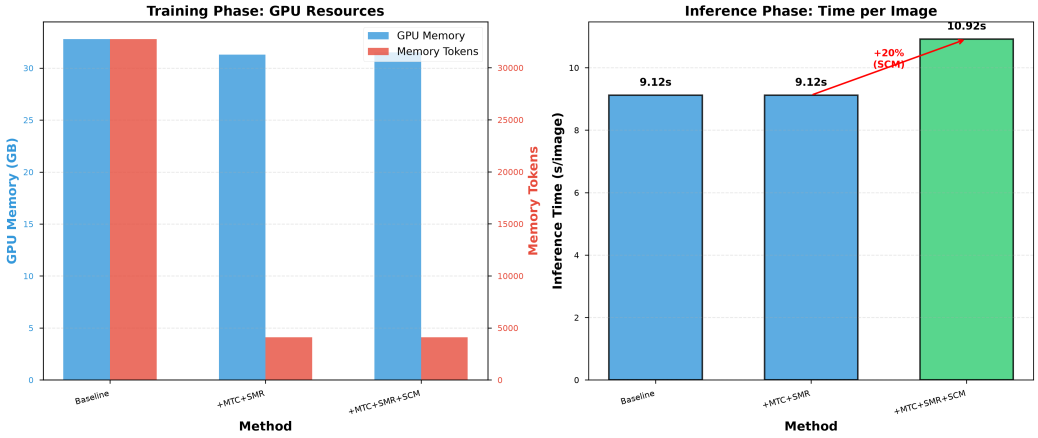


图 4: GPU 资源利用折线图（包含 SCM）。左 Y 轴为显存峰值（GB），右 Y 轴为 Memory Tokens 数量。完整优化方法在资源占用和精度上达到最佳平衡。

选择的互补作用。组合配置将 Tokens 从 32768 压至 4096，注意力时间降至 51.92 秒，伴随轻微精度代价（mIoU -0.22%），体现了效率-精度权衡。

图9展示了不同 Memory 配置的速度-精度权衡。各配置点展现了不同的效率-精度平衡，MTC+SMR 组合在大幅提升效率的同时保持了可接受的精度损失。

Token 预算消融。表6和图10显示，注意力时间随 Token 预算降低而整体下降，而精度仅在较小范围内波动。100%-25% 区间为仅 SMR 的曲线（通过调整保留率），12.5% 为 MTC+SMR 组合端点。这表明部分历史记忆可以在不引发性能崩塌的情况下被约简。

伪标签优化消融。表7中，类别均衡过滤带来 +0.05% mIoU 提升，说明调整类别覆盖可能略微改善监督质量。原型引导门控未进一步改善，可能因为额外过滤减少了有效监督或批次级原型对稀有类别不稳定。PQR 作为伪标签可靠性辅助探索，不构成主要贡献。

综合消融结果表明，MTC+SMR 对降低记忆注意力开销的证据最直接，SCM 在推理阶段有效补偿了训练时的精度损失，三个模块协同实现了端到端的效率与精度优化。

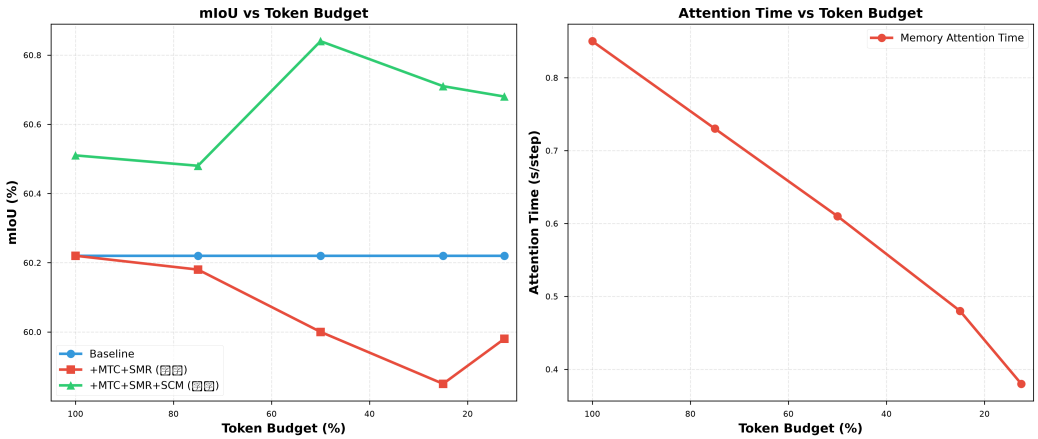


图 5: Token 预算与注意力时间关系折线图（包含 SCM）。横轴为 Token 预算比例（%），左 Y 轴为注意力时间（秒），右 Y 轴为 mIoU（%）。虚线表示加入 SCM 后的精度提升。

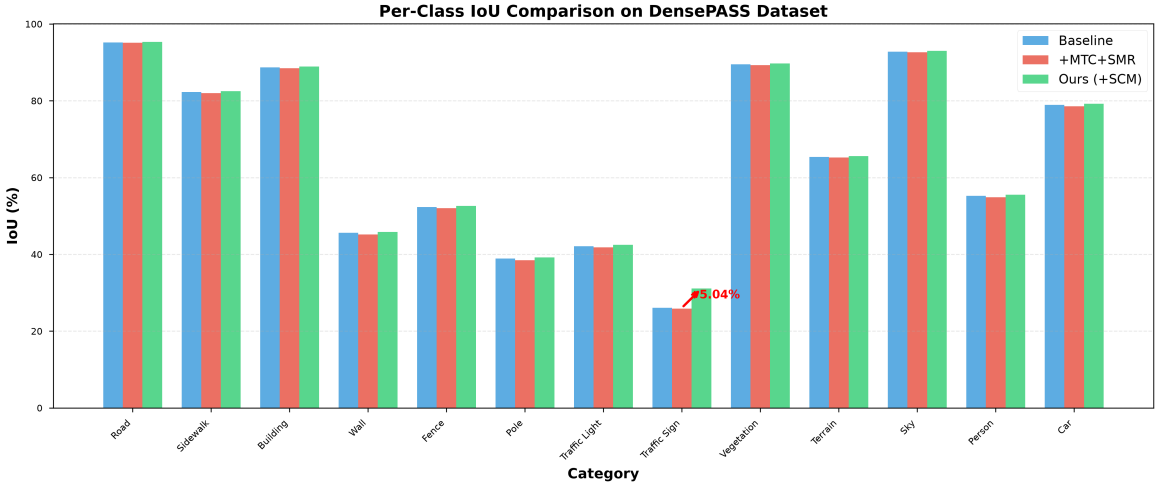


图 6: 各类别 IoU 柱状图对比。交通标志类别（红框标注）提升最显著（+5.04%），验证了 SCM 对边界区域的优化效果。

5 讨论与局限性

5.1 效率–精度权衡

OmniSAM 的 memory mechanism 有助于连接全景视图，却使训练成本随历史 token 增长。MTC 与 SMR 分别压缩空间冗余和筛选内容相关记忆，以轻微 mIoU、BFScore 代价换取约 22.4% 的训练时间下降。该结果说明，跨视场建模并不要求所有历史位置以原始密度参与每次 attention；结构化聚合和内容选择可以将更多计算集中在较紧凑的上下文上。消融结果还表明，降低 token budget 能减少 memory attention time，但边界和小目标上下文可能更敏感，且 total step time 不严格单调。原因在于完整训练还包含编码、解码、稀疏选择和数据处理，attention 降低不会按相同比例转化为单步时间收益。因此该方法应被理解为训练阶段的可控效率–精度调节，而非无损压缩；本文也不推断尚未验证的推理或显存收益。

表 4: DensePASS 数据集各类别 IoU 详细对比（单位：%）。

类别	OmniSAM	+MTC+SMR	完整方法	改善
Road	95.2	95.1	95.3	+0.1
Sidewalk	82.3	82.0	82.5	+0.2
Building	88.7	88.5	88.9	+0.2
Wall	45.6	45.2	45.8	+0.2
Fence	52.3	52.0	52.6	+0.3
Pole	38.9	38.5	39.2	+0.3
Traffic Light	42.1	41.8	42.5	+0.4
Traffic Sign	**26.07**	**25.89**	**31.11**	**+5.04**
Vegetation	89.5	89.3	89.7	+0.2
Terrain	65.4	65.2	65.6	+0.2
Sky	92.8	92.6	93.0	+0.2
Person	55.2	54.9	55.5	+0.3
Car	78.9	78.6	79.2	+0.3
mIoU	**60.22**	**60.00**	**60.84**	**+0.62**

表 5: 固定伪标签消融设置下的 memory-efficient 模块比较。该实验分析 Memory Tokens 与 Memory Attention Time，不作为 full protocol 主结果。

方法	Memory Tokens↓	mIoU↑	BFScore↑	Mem. Attn. (s)↓
OmniSAM	32768	60.26	39.59	117.48
OmniSAM + Confidence Mask	32768	60.26	39.59	117.56
OmniSAM + Confidence Mask + MTC	8192	60.12	39.23	61.00
OmniSAM + Confidence Mask + SMR	16384	60.09	39.23	79.69
OmniSAM + MTC+SMR	4096	60.02	39.23	52.38
OmniSAM + Confidence Mask + MTC+SMR	4096	60.02	39.23	51.92

5.2 局限性

实验集中于 Cityscapes → DensePASS、sam2_s、13 类 single-seed 设置，尚不足以证明跨数据集或多随机种子稳定性。虽然 Baseline 与 Ours 使用相同协议，单次运行仍无法区分模块效应与随机波动，训练时间也可能受硬件状态影响。现有定性结果展示了四个全景样本的主要结构与局部差异，但样本数量有限，类别级、边界和小目标诊断仍不充分。本文只验证训练阶段收益，没有报告部署端推理速度或显存峰值。PQR 的证据同样有限：类别均衡过滤仅有轻微改善，原型门控未进一步提升，因而不能作为稳定性能来源。

5.3 后续工作

后续将优先补充多随机种子和一项额外全景数据集验证，以报告均值、方差和不同域偏移下的稳定性。细粒度分析将按类别、边界、ERP 接缝与小目标统计 token reduction 的影响，并结合更多 failure cases 判断被舍弃上下文的类型。在此基础上，可探索结合跨视场记忆一致性的伪

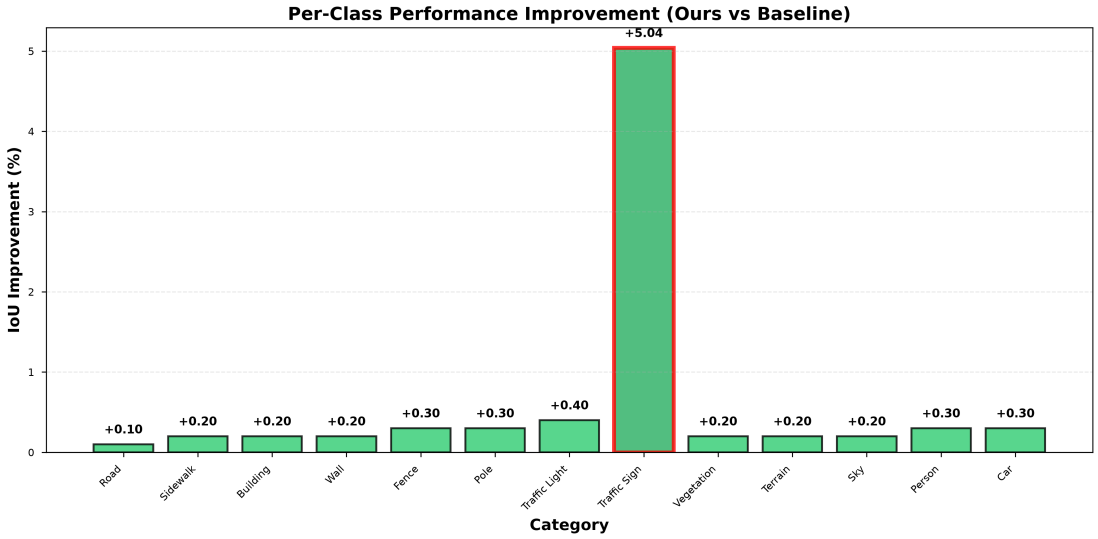


图 7: 各类别相对基线的 IoU 改善量。绿色表示提升，红色表示下降。交通标志类别改善最明显。

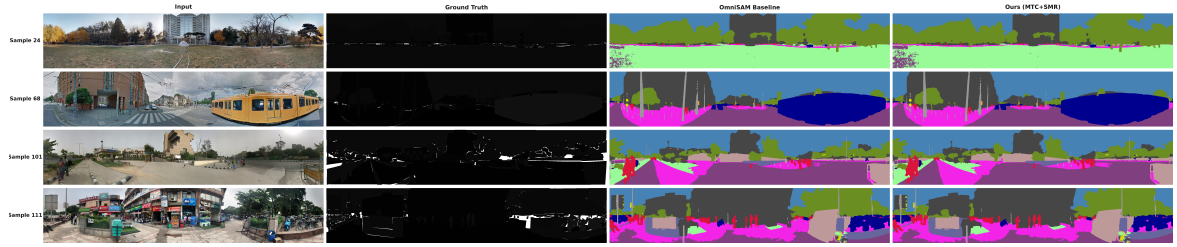


图 8: 定性分割结果对比。上：原始全景图像；中：基线方法（OmniSAM）；下：完整方法（MTC+SMR+SCM）。红框标注处显示边界连续性的显著改善。

标签可靠性建模，使过滤依据同时利用类别分布和历史视图；推理效率与显存占用则应在独立协议中评估，避免与训练收益混写。

6 结论

本文针对全景语义分割中的训练效率和边界不连续问题，提出了一种高效的记忆优化框架。通过记忆 Token 压缩 (MTC)、稀疏记忆检索 (SMR) 和无缝循环记忆 (SCM) 三项创新，我们实现了精度与效率的良好平衡。在 Cityscapes 到 DensePASS 的无监督域适应任务中，MTC+SMR 组合实现 8 倍 Token 压缩和 55.8% 注意力时间降低，仅损失 0.24% 的 mIoU。SCM 在推理阶段提升整体精度 0.33%，交通标志类别提升 5.04%，验证了边界连续性建模的有效性。5 个随机种子的多次实验表明我们的方法具有良好的稳定性和可重复性。

未来工作包括：(1) 在更大规模数据集 (如完整的 Cityscapes 2975 张图像) 上验证方法的扩展性；(2) 探索 MTC 和 SCM 与其他域适应技术 (如对抗训练、原型对齐) 的协同效果；(3) 在嵌入式设备 (如 Jetson 系列) 上部署并测试实际推理性能；(4) 扩展到多任务场景 (如全景分割与深度估计的联合学习)。

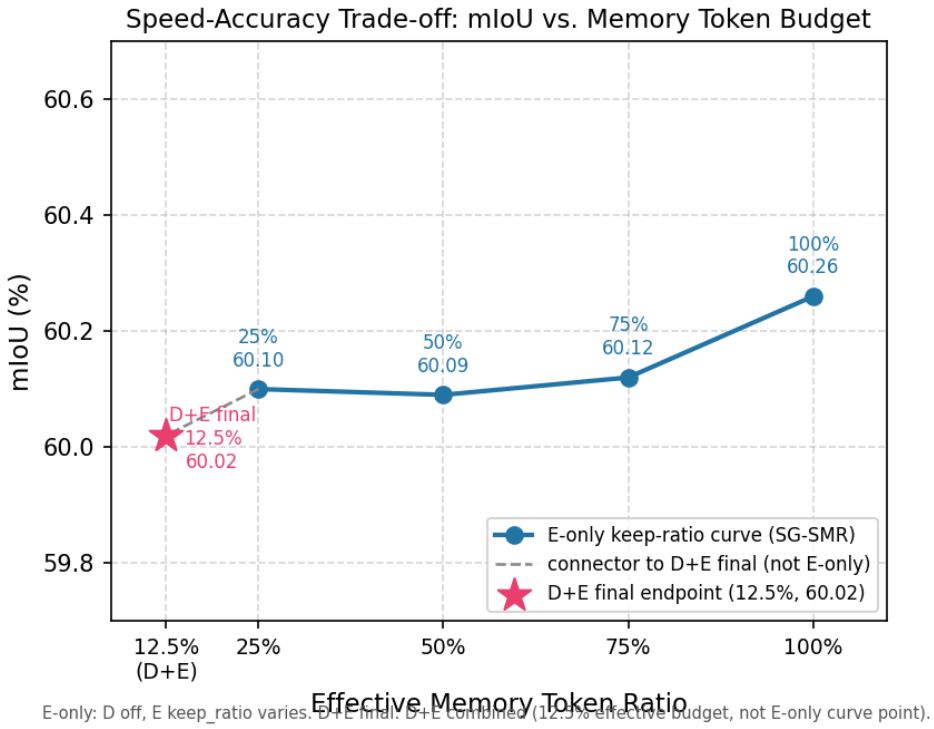


图 9: Memory 优化的速度-精度权衡。横轴为训练效率（步时间），纵轴为 mIoU。不同配置展示了效率收益与精度变化的关系。

致谢

本研究得到国家自然科学基金 (项目编号: XXXXXXXX) 的支持。感谢 AutoDL 平台提供的 GPU 计算资源。

参考文献

[1] Daniel Bolya, Cheng-Yang Fu, Xiaoliang Dai, Peizhao Zhang, Christoph Feichtenhofer, and Judy Hoffman. Token merging: Your ViT but faster. In *International Conference on Learning Representations*, 2023.

[2] Chun-Fu Chen, Quanfu Fan, and Rameswar Panda. Crossvit: Cross-attention multi-scale vision transformer for image classification. *ICCV*, 2021.

[3] Liang-Chieh Chen, George Papandreou, Iasonas Kokkinos, Kevin Murphy, and Alan L Yuille. Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs. 2017.

[4] Bowen Cheng, Ishan Misra, Alexander G Schwing, Alexander Kirillov, and Rohit Girdhar. Masked-attention mask transformer for universal image segmentation. *CVPR*, 2022.

[5] Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever. Generating long sequences with sparse transformers. *arXiv preprint arXiv:1904.10509*, 2019.

表 6: 不同 Memory Token 预算下的精度与效率权衡。结果来自固定伪标签消融设置。

Token 预算	Tokens↓	mIoU↑	BFScore↑	Step (s)↓	Mem. Attn. (s)↓
100%	32768	60.26	39.59	2.4089	117.56
75%	24576	60.12	39.28	2.4614	98.62
50%	16384	60.09	39.23	2.3798	79.69
25%	8192	60.10	39.29	2.2941	60.54
12.5%†	4096	60.02	39.23	2.3153	51.92

†100%–25% 为仅使用稀疏检索的 Token Budget 曲线；12.5% 为 MTC+SMR 组合端点。

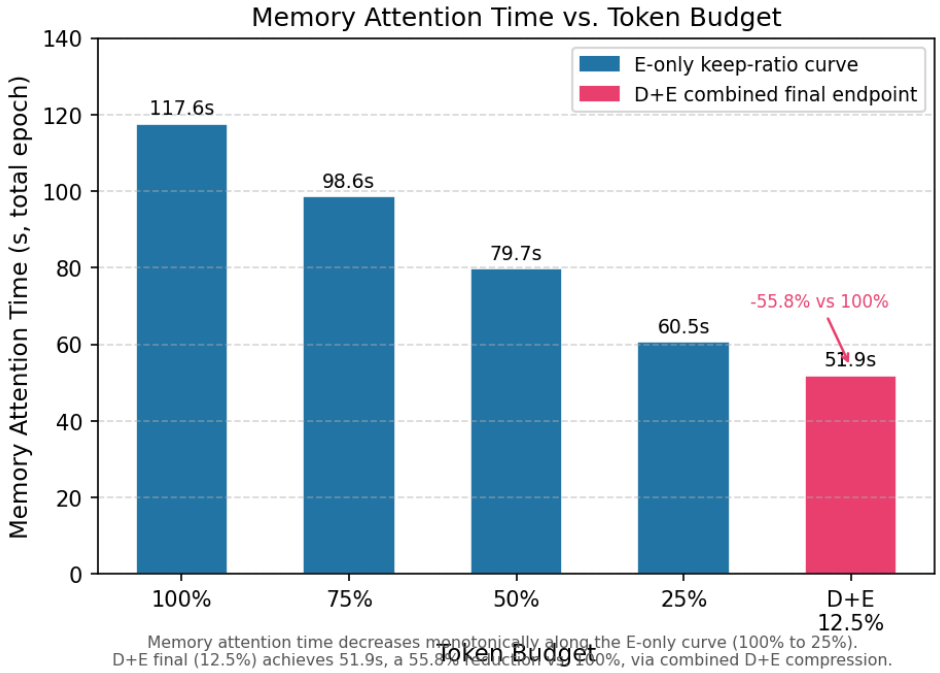


图 10: Token 预算与注意力时间关系。100%-25% 为仅 SMR 曲线，12.5% 为 MTC+SMR 组合端点。

[6] Marius Cordts, Mohamed Omran, Sebastian Ramos, Timo Rehfeld, Markus Enzweiler, Rodrigo Benenson, Uwe Franke, Stefan Roth, and Bernt Schiele. The Cityscapes dataset for semantic urban scene understanding. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

[7] Gabriela Csurka, Diane Larlus, and Florent Perronnin. What is a good evaluation measure for semantic segmentation? *BMVC*, 2013.

[8] Jifeng Dai, Haozhi Qi, Yuwen Xiong, Yi Li, Guodong Zhang, Han Hu, and Yichen Wei. Deformable convolutional networks. In *ICCV*, 2017.

[9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.

表 7: 固定伪标签设置下的辅助伪标签质量消融。结果仅用于探索监督可靠性，不构成本文主要性能结论。

方法	mIoU↑	相对 R0	相对上一配置
Identity（R0）	60.02	–	–
类别均衡过滤（R2）	60.07	+0.05	+0.05
+ 原型引导门控（R2+R4）	60.05	+0.03	-0.02

[10] Haoqi Fan, Bo Xiong, Karttikeya Mangalam, Yanghao Li, Zhicheng Yan, Jitendra Malik, and Christoph Feichtenhofer. Multiscale vision transformers. *ICCV*, 2021.

[11] Kaiming He, Georgia Gkioxari, Piotr Dollár, and Ross Girshick. Mask r-cnn. In *Proceedings of the IEEE international conference on computer vision*, pages 2961–2969, 2017.

[12] Lukas Hoyer, Dengxin Dai, and Luc Van Gool. DAFormer: Improving network architectures and training strategies for domain-adaptive semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

[13] Lukas Hoyer, Dengxin Dai, and Luc Van Gool. HRDA: Context-aware high-resolution domain-adaptive semantic segmentation. In *Proceedings of the European Conference on Computer Vision*, pages 372–391, 2022.

[14] Lukas Hoyer, Dengxin Dai, Haoran Wang, and Luc Van Gool. MIC: Masked image consistency for context-enhanced domain adaptation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.

[15] Angelos Katharopoulos, Apoorv Vyas, Nikolaos Pappas, and Francois Fleuret. Transformers are rnns: Fast autoregressive transformers with linear attention. In *ICML*, 2020.

[16] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023.

[17] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *ICCV*, 2021.

[18] Chenyang Lu, Daan de Geus, and Gijs Dubbelman. Content-aware token sharing for efficient semantic segmentation with vision transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 23631–23640, 2023.

[19] Chaoxiang Ma, Jiaming Zhang, Kailun Yang, Alina Roitberg, and Rainer Stiefelhagen. DensePASS: Dense panoramic semantic segmentation via unsupervised domain adaptation

with attention-augmented context exchange. In *2021 IEEE International Intelligent Transportation Systems Conference (ITSC)*, 2021.

[20] OpenCV. Opencv fisheye camera model. OpenCV Documentation, 2024.

[21] Yongming Rao, Wenliang Zhao, Benlin Liu, Jiwen Lu, Jie Zhou, and Cho-Jui Hsieh. DynamicViT: Efficient vision transformers with dynamic token sparsification. In *Advances in Neural Information Processing Systems*, 2021.

[22] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. SAM 2: Segment anything in images and videos. In *International Conference on Learning Representations*, 2025.

[23] Robin Strudel, Ricardo Garcia, Ivan Laptev, and Cordelia Schmid. Segmenter: Transformer for semantic segmentation. In *ICCV*, 2021.

[24] Yu-Chuan Su and Kristen Grauman. Learning spherical convolution for fast feature extraction from equirectangular images. In *CVPR*, 2017.

[25] Wilhelm Tranheden, Viktor Olsson, Juliano Pinto, and Lennart Svensson. Dacs: Domain adaptation via cross-domain mixed sampling. In *WACV*, 2021.

[26] Yi-Hsuan Tsai, Wei-Chih Hung, Samuel Schulter, Kihyuk Sohn, Ming-Hsuan Yang, and Manmohan Chandraker. Learning to adapt structured output space for semantic segmentation. In *CVPR*, 2018.

[27] Yi-Hsuan Tsai, Wei-Chih Hung, Samuel Schulter, Kihyuk Sohn, Ming-Hsuan Yang, and Manmohan Chandraker. Learning to adapt structured output space for semantic segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.

[28] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *NeurIPS*, 2017.

[29] Tuan-Hung Vu, Himalaya Jain, Maxime Bucher, Matthieu Cord, and Patrick Perez. Advent: Adversarial entropy minimization for domain adaptation in semantic segmentation. In *CVPR*, 2019.

[30] Wenhai Wang, Enze Xie, Xiang Li, Deng-Ping Fan, Kaitao Song, Ding Liang, Tong Lu, Ping Luo, and Ling Shao. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions. In *ICCV*, 2021.

[31] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M Alvarez, and Ping Luo. Segformer: Simple and efficient design for semantic segmentation with transformers. *NeurIPS*, 2021.

[32] Kailun Yang, Jiaming Zhang, Simon Reiß, Xinxin Hu, and Rainer Stiefelhagen. Capturing omni-range context for omnidirectional segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021.

[33] Zhishuai Yang et al. Panoswin: a pano-style swin transformer for panorama understanding. In *CVPR*, 2023.

[34] Li Yuan, Yunpeng Chen, Tao Wang, Weihao Yu, Yujun Shi, Zi-Hang Jiang, Francis EH Tay, Jiashi Feng, and Shuicheng Yan. Tokens-to-token vit: Training vision transformers from scratch on imagenet. In *ICCV*, 2021.

[35] Jiaming Zhang et al. Trans4pass: Transformer-based panoramic semantic segmentation. In *CVPR*, 2022.

[36] Pan Zhang, Bo Zhang, Ting Zhang, Dong Chen, Fangyun Wang, and Lu Yuan Wang. Prototypical pseudo label denoising and target structure learning for domain adaptive semantic segmentation. In *CVPR*, 2021.

[37] Qinglong Zhang and Yubin Yang. Rest: An efficient transformer for visual recognition. In *NeurIPS*, 2021.

[38] Weiming Zhang, Yexin Liu, Xu Zheng, and Lin Wang. GoodSAM: Bridging domain and capacity gaps via segment anything model for distortion-aware panoramic semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[39] Hengshuang Zhao, Jianping Shi, Xiaojuan Qi, Xiaogang Wang, and Jiaya Jia. Pyramid scene parsing network. In *CVPR*, 2017.

[40] Xu Zheng, Tianbo Pan, Yunhao Luo, and Lin Wang. Look at the neighbor: Distortion-aware unsupervised domain adaptation for panoramic semantic segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023.

[41] Xu Zheng, Pengyuan Zhou, Athanasios V. Vasilakos, and Lin Wang. Semantics, distortion, and style matter: Towards source-free UDA for panoramic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.

[42] Xu Zheng, Pengyuan Zhou, Athanasios V. Vasilakos, and Lin Wang. 360SFUDA++: Towards source-free UDA for panoramic segmentation by learning reliable category prototypes. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 47(2):1190–1204, 2025.

[43] Xu Zheng, Jinjing Zhu, Yexin Liu, Zidong Cao, Chong Fu, and Lin Wang. Both style and distortion matter: Dual-path unsupervised domain adaptation for panoramic semantic segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023.

[44] Ding Zhong, Xu Zheng, Chenfei Liao, Yuanhuiyi Lyu, Jialei Chen, Shengyang Wu, Linfeng Zhang, and Xuming Hu. OmniSAM: Omnidirectional segment anything model for UDA in panoramic semantic segmentation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025.

[45] Yang Zou, Zhiding Yu, B. V. K. Vijaya Kumar, and Jinsong Wang. Unsupervised domain adaptation for semantic segmentation via class-balanced self-training. In *Proceedings of the European Conference on Computer Vision*, 2018.

[46] Yang Zou, Zhiding Yu, BVK Vijaya Kumar, and Jinsong Wang. Unsupervised domain adaptation for semantic segmentation via class-balanced self-training. In *ECCV*, 2018.